

Отчет

Лабораторная работа 3-1. Проектирование архитектуры хранилища больших данных

Цель работы: разработать комплексную архитектуру хранилища больших данных для предложенного бизнес-сценария, обосновать выбор технологического стека и визуализировать потоки данных.

Вариант 17

Геологоразведочная компания: обработка и анализ сейсмических данных, построение 3D-моделей месторождений, оптимизация бурения. Источники: данные сейсморазведки (файлы SEG-Y), данные с буровых установок.

1. Требования к данным

1.1 Объём данных

- SEG-Y файлы: 500 ТБ — 20 ПБ в год
- Телеметрические данные с датчиков буровых установок: ~1 ГБ/сутки на одну буровую
- Рост данных: 30–50% в год

1.2 Скорость поступления данных

- SEG-Y: раз в неделю, партиями по 5–50 ТБ
- Телеметрические данные с датчиков: потоковая (непрерывно в режиме реального времени, обновление данных каждую секунду)

1.3 Типы данных

- Структурированные: телеметрические данные с датчиков, лабораторные измерения
- Полуструктурированные: метаданные буровых, лабораторные отчёты в формате JSON/XML
- Неструктурированные: SEG-Y, изображения, 3D-модели

1.4 Требования к обработке

- Обработка сейсмических данных (SEG-Y) – пакетная обработка, запуск еженедельно
- Построение и обновление 3D-моделей месторождений – ежемесячно
- Обучение моделей машинного обучения (прогнозирование аварий, оптимизация бурения) – ежеквартально
- Мониторинг параметров бурения – в режиме реального времени
- Формирование алертов и KPI для инженеров – в режиме реального времени
- Отчётность для руководства (ход бурения, эффективность, затраты) – ежедневно и еженедельно

1.5 Доступность данных

- Время отклика для телеметрических данных: <5 секунд
- Доступность системы для телеметрии: 99,9% (допустимое время простоя $\approx 8,8$ часов в год)
- Время отклика для пакетных данных (SEG-Y, 3D-модели, лабораторные данные): <60 минут
- Доступность системы для пакетных данных и отчётов: 99,5% (допустимое время простоя ≈ 44 часа в год)

1.6 Безопасность

- Шифрование данных в покое и при передаче
- Разграничение доступа
- Аудит действий с данными

2. Архитектура хранилища больших данных

2.1 Компоненты архитектуры

Источники данных

- SEG-Y (сейсмика)
- Телеметрические данные с датчиков (буровые установки)
- Метаданные и лабораторные данные
- 3D-модели интерпретаций

Слой хранения данных

- Snowflake — единое хранилище и вычисления: зоны RAW/CURATED/ANALYTICS, стейджи для загрузки крупных файлов (в т.ч. SEG-Y и 3D), поддержка JSON/XML через тип VARIANT, ссылки на большие артефакты; коннекторы для Spark/Flink/Jupyter/Power BI; масштабирование отдельными «виртуальными складами»; есть time-travel/клоны и доступ по ролям.

Слой обработки данных

- Apache Spark – пакетная обработка данных, построение 3D-моделей, подготовка данных для ML.
- Apache Flink – потоковая обработка телеметрии и генерация алертов в реальном времени.

Слой аналитики и визуализации

- Jupyter Notebook + MLflow – интерактивная аналитика данных и управление обучением моделей машинного обучения.
- ParaView – визуализация 3D-моделей месторождений для инженеров и геологов.
- Power BI – дашборды для руководства и мониторинга ключевых показателей бурения.

Слой управления данными

- OpenMetadata – управление метаданными, каталогизация данных и отслеживание их происхождения.

Слой оркестрации и мониторинга

- Apache Airflow – оркестрация пакетных ETL-процессов.
- Prometheus + Grafana – мониторинг производительности и алертинг.



4. Процесс обработки данных

- Источники: файлы SEG-Y, телеметрия буровых, лабораторные/метаданные, 3D-модели.
- Пакетные файлы загружаются в Snowflake: сначала в стейдж RAW, потом в таблицы. Этим управляет Airflow.
- Поточная телеметрия обрабатывается во Flink в реальном времени и сразу пишется в таблицы Snowflake с агрегатами и KPI.
- Пакетная обработка делает Spark по расписанию: разбирает SEG-Y, считает показатели, готовит данные для 3D и ML и сохраняет в Snowflake (CURATED/ANALYTICS).
- Airflow запускает все задачи, следит за порядком шагов и повторами при сбоях.
- Аналитики работают в Jupyter и ведут эксперименты в MLflow, беря данные из Snowflake.
- ParaView показывает 3D-структуры на основе подготовленных срезов; ссылки и метаданные лежат в Snowflake.
- Power BI подключён к Snowflake и показывает отчёты и метрики почти в реальном времени.
- OpenMetadata собирает описания таблиц и цепочки происхождения данных из Snowflake, Airflow, Spark и Flink.

5. Масштабирование и отказоустойчивость

- Snowflake масштабируется за счёт отдельных вычислительных «складов» для разных задач; при росте нагрузки они могут автоматически расширяться.
- Spark и Flink масштабируются горизонтально (добавляем рабочие узлы по мере роста

данных).

- Flink сохраняет точки восстановления потоков, чтобы быстро подняться после сбоя.
- Airflow перезапускает упавшие шаги и ведёт историю запусков.
- Prometheus собирает метрики всех сервисов, Grafana показывает панели и отправляет предупреждения.
- В Snowflake есть time-travel и клоны таблиц для отката и быстрого восстановления критичных наборов.

6. Безопасность

- Все соединения по TLS, в Snowflake данные шифруются и «на проводе», и «на диске».
- Доступ по ролям (RBAC). Можно ограничивать видимость строк и колонок и маскировать чувствительные поля.
- Единый вход через корпоративный SSO (например, SAML/OAuth) и сетевые правила для контроля доступа.
- Действия и запросы журналируются в Snowflake; OpenMetadata хранит каталог, владельцев и метки чувствительности.
- План восстановления: откаты в Snowflake, перезапуск DAGов в Airflow, перезапуск потоков во Flink.
- События безопасности и нарушения SLA попадают в Prometheus и видны в Grafana, ответственные получают уведомления.